

# רגרסיה ומודלים לינאריים 52320 תשע"ז 2016-17

## בוהן 1 26.04.2017

בבוהן שאלות אמריקאיות ושאלות פתוחות.

משקל כל שאלה הוא 25 נקודות כך שמספר הנקודות הכולל הוא 125. בכל מקרה, ציון הבוחן הוא 100 לכל היותר. שימו לב שהשאלות הן בדרגת קושי שונה כך שמומלץ לא להתעכב יותר על המידה על שאלה מסויימת. אנא הקפידו על ההנחיות הבאות:

- כתבו את ת.ז. (לא את השם!) בראש כל עמוד של טופס הבחינה.

- אין לצרף לטופס דפים נוספים.

- אין לתלוש דפים מטופס הבחינה.

לתשומת לבכם לגבי השאלות הפתוחות:

- תשובה סופית ללא דרך לא תזכה בניקוד כלשהו (ציון 0).

- בשאלות הפתוחות יש לכתוב את הפתרון רק במקום המוקצה לכך, מעל לכל קו כתבו שורה אחת בלבד בכתב יד קריא. (השאלות נכתבו כך שניתן לכתוב פתרון תמציתי לכל סעיף).

- מגבלת המקום תאכף באופן קפדני. פתרונות אשר יחרגו מהמקום המותר, יהיו בכתב קטן מכדי שיהיה קריא, ו/או יכללו יותר משורת כתב אחת לכל קו לא ייבדקו.

- מומלץ מאוד לפתור תחילה את השאלה במחברת הטיוטה ולהעתיק את עיקר הפתרון אל הטופס רק לאחר בדיקה. חומר עזר מותר: מחשבון, דף נוסחאות דו צדדי

משך הבוחן: שעה

**בהצלחה!**

סימונים: נכתוב משתנים בכתיב וקטורי, כאשר  $x, y, \dots$  הם וקטורי עמודה.  $x_i$  מסמן את האיבר ה- $i$  של וקטור  $x$  ו- $\bar{x}$  מסמן את הממוצע של וקטור  $x$ . עבור שני וקטורים  $x, y$  באורך  $n$  המכפלה הסקלרית שלהם היא  $x^T y = \sum_{i=1}^n x_i y_i$ .  
 תזכורת: נגדיר מודל לרגרסיה פשוטה עם חותך:  $y_i = \beta_0 + \beta_1 x_i + \epsilon_i$  עבור נתונים  $(x_1, y_1), \dots, (x_n, y_n)$ . עבור מודל זה שגיאת הרבועים הפחותים  $SSE = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n \epsilon_i^2$  ניתנת לכתיבה בצורות הבאות:  
 $SSE = (y - \hat{\beta}_0 - \hat{\beta}_1 x)^T (y - \hat{\beta}_0 - \hat{\beta}_1 x) = (y - \bar{y})^T (y - \bar{y}) - \hat{\beta}_1^2 (x - \bar{x})^T (x - \bar{x})$   
 $\hat{\beta}_1 = \frac{(x - \bar{x})^T (y - \bar{y})}{(x - \bar{x})^T (x - \bar{x})}, \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$

1. עבור מודל הרגרסיה הפשוטה עם חותך לעיל, יהיה  $\hat{y}$  וקטור התחזיות ויהיה  $e = y - \hat{y}$  וקטור השאריות. אילו מהגדלים הבאים תמיד שווים לאפס?  $\sum_{i=1}^n e_i, \sum_{i=1}^n x_i e_i, \sum_{i=1}^n y_i e_i$   $n=3$ , (iii)  
 (א) כולם  $D = \{0, 0, 0, 1, 1, 1, -1, 0, 0\}$   
 (ב) אף אחד  $\hat{\beta}_1 = \frac{1-0}{2-0} = \frac{1}{2}$   
 (ג) רק  $\sum_{i=1}^n y_i e_i, \sum_{i=1}^n x_i e_i$   
 (ד) רק  $\sum_{i=1}^n e_i$   
 (ה) רק  $\sum_{i=1}^n e_i, \sum_{i=1}^n x_i e_i$   
 (ו) אף אחת מהתשובות לעיל אינה נכונה  $\hat{\beta}_0 = \frac{1}{3} - 0 = \frac{1}{3}$   
 $\hat{\beta}_1 = \frac{1}{3} - 0 = \frac{1}{3}$   
 $\hat{\beta}_0 = \frac{1}{3}, \hat{\beta}_1 = \frac{1}{3}$   
 $e = (-\frac{1}{3}, \frac{1}{6}, \frac{1}{6})$   
 $\sum_{i=1}^n e_i = 0 + \frac{1}{6} + \frac{1}{6} = \frac{1}{3} \neq 0$   
 2. נניח כעת כי נתונים כל הסכומים הבאים עבור נתונים  $(x_1, y_1), \dots, (x_n, y_n)$ :  
 $S_x = \sum_{i=1}^n x_i = -3.8, S_y = \sum_{i=1}^n y_i = 32.6, S_{xx} = x^T x = 14.45, S_{yy} = y^T y = 69.64, S_{xy} = x^T y = -15.45, n = 20$

חשבו את  $\hat{\beta}_0, \hat{\beta}_1$  ואת האומד לשונות  $s^2$  עבור מודל הרגרסיה עם חותך והנתונים שלעיל.

$$\hat{\beta}_1 = \frac{S_{xy} - \frac{1}{n} S_x S_y}{S_{xx} - \frac{1}{n} S_x^2} = \frac{-15.45 - \frac{1}{20} (-3.8) 32.6}{14.45 - \frac{1}{20} (-3.8)^2} = \frac{-9.256}{13.728} = -0.674$$

$$\hat{\beta}_0 = \bar{y} - \bar{x} \hat{\beta}_1 = \frac{1}{20} 32.6 - \frac{1}{20} (-3.8) (-0.674) = 1.502$$

$$SSE = SST - SSR = \sum_{i=1}^n (y_i - \bar{y})^2 - \sum_{i=1}^n (\hat{\beta}_0 + \hat{\beta}_1 x_i - \hat{\beta}_0 - \hat{\beta}_1 \bar{x})^2 = S_{yy} - \frac{1}{n} S_y^2 - \hat{\beta}_1^2 (S_{xx} - \frac{1}{n} S_x^2)$$

$$= 69.64 - \frac{1}{20} (32.6)^2 - (-0.674)^2 (14.45 - \frac{1}{20} (-3.8)^2) = 10.266$$

$$s^2 = \frac{SSE}{n-2} = \frac{10.266}{18} = 0.57$$

3. נגדיר כעת מודל רגרסיה ללא חותך:  $y_i = \gamma_1 x_i + \epsilon_i$  עבור נתונים  $(x_1, y_1), \dots, (x_n, y_n)$ . הוכיחו שבמודל זה אומד הרבועים הפחותים  $\hat{\gamma}_1$  עבור  $\gamma_1$  שווה ל- $\frac{x^T y}{x^T x}$ .

$$\hat{\gamma}_1 = \arg \min_{\gamma_1} \sum_{i=1}^n (y_i - \gamma_1 x_i)^2 \quad F(\gamma_1) \equiv \sum_{i=1}^n (y_i - \gamma_1 x_i)^2$$

$$\frac{dF}{d\gamma_1} = \sum_{i=1}^n 2(y_i - \gamma_1 x_i)(-x_i) = 0 \Rightarrow \sum_{i=1}^n x_i y_i = \gamma_1 \sum_{i=1}^n x_i^2$$

$$\Rightarrow \hat{\gamma}_1 = \frac{\sum_{i=1}^n x_i y_i}{\sum_{i=1}^n x_i^2} = \frac{x^T y}{x^T x}$$

$$\frac{d^2 F}{d\gamma_1^2} = \sum_{i=1}^n 2x_i^2 > 0 \rightarrow \text{מינימום}$$

4. עבור רגרסיה לינארית פשוטה, עם שגיאות נורמליות  $\epsilon \sim N(0, \sigma^2 I_n)$  עבור  $\sigma^2 > 0$  יהיו  $\hat{\beta}_0, \hat{\beta}_1, \bar{y}$  אומדי הרבועים הפחותים הרגילים וממוצע ה- $y_i$  בהתאמה עבור מדגם  $D = (x_1, y_1), \dots, (x_n, y_n)$  עם  $n > 1$ . שלושת המשתנים המקריים  $\hat{\beta}_0, \hat{\beta}_1, \bar{y}$  הם:

- (א) תלויים אך בלתי תלויים בזוגות  
 (ב) בלתי תלויים  
 (ג) תלויים וכל הזוגות תלויים  
 (ד) תלויים, חלק מהזוגות תלויים וחלק מהזוגות בלתי תלויים
- $\hat{\beta}_0 = \bar{y} - \bar{x} \hat{\beta}_1 \Rightarrow \hat{\beta}_0, \hat{\beta}_1, \bar{y}$  קובעים את  $\hat{\beta}_0$  ו- $\hat{\beta}_1$  (כאן כוונה).  
 $\text{cov}(\hat{\beta}_0, \hat{\beta}_1) = 0 \Rightarrow \text{cov}(\bar{y}, \hat{\beta}_1) = 0$   
 $\text{cov}(\hat{\beta}_0, \bar{y}) = \text{cov}(\bar{y} - \bar{x} \hat{\beta}_1, \bar{y}) = \text{var}(\bar{y}) - \bar{x} \text{cov}(\hat{\beta}_1, \bar{y}) = \text{var}(\bar{y}) > 0$   
 כלומר  $\hat{\beta}_0, \bar{y}$  תלויים וכל הזוגות תלויים.

5. נתונה המטריצה  $A = \begin{bmatrix} 1 & 1 \\ 1 & 1 \\ 2 & -1 \end{bmatrix}$  והוקטור  $v = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}$ . תהיה  $P_A = A[A^T A]^{-1} A^T$  מטריצת הטלה על תת המרחב הנפרש על ידי עמודות  $A$  ותהי  $P_{A^\perp}$  מטריצת הטלה על תת המרחב הניצב לתת המרחב הנפרש על ידי עמודות  $A$ . חשבו את הגדלים הבאים: (כתבו את התוצאות כוקטורי שורה. כתבו רק תוצאה סופית - אין צורך להראות דרך)

$$A^T A = \begin{bmatrix} 1 & 1 & 2 \\ 1 & 1 & -1 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 1 & 1 \\ 2 & -1 \end{bmatrix} = \begin{bmatrix} 6 & 0 \\ 0 & 3 \end{bmatrix} \Rightarrow [A^T A]^{-1} = \begin{bmatrix} 1/6 & 0 \\ 0 & 1/3 \end{bmatrix}$$

$$P_A v = \underline{\left( \frac{1}{2}, \frac{1}{2}, 0 \right)} \quad (\text{א})$$

$$P_{A^\perp} v = \underline{\left( \frac{1}{2}, -\frac{1}{2}, 0 \right)} \quad (\text{ב})$$

$$P_{A^\perp} P_A v = \underline{(0, 0, 0)} \quad (\text{ג})$$

$$P_A v = A [A^T A]^{-1} A^T v = A [A^T A]^{-1} \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix} = A [A^T A]^{-1} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

$$= A \begin{bmatrix} 1/6 & 0 \\ 0 & 1/3 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \end{bmatrix} = A \begin{bmatrix} 1/6 \\ 1/3 \end{bmatrix} = \begin{bmatrix} 1 & 1 \\ 1 & 1 \\ 2 & -1 \end{bmatrix} \begin{bmatrix} 1/6 \\ 1/3 \end{bmatrix} = \begin{bmatrix} 1/2 \\ 1/2 \\ 0 \end{bmatrix}$$

$$P_{A^\perp} v = v - P_A v = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix} - \begin{bmatrix} 1/2 \\ 1/2 \\ 0 \end{bmatrix} = \begin{bmatrix} 1/2 \\ -1/2 \\ 0 \end{bmatrix}$$

$$P_A v \in \text{Span}(A) \Rightarrow P_A v \perp \text{Span}(A)^\perp$$

$$\Rightarrow P_{A^\perp} P_A v = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$$

סימונים: נכתוב משתנים בכתיב וקטורי, כאשר  $x, y, \dots$  הם וקטורי עמודה.  $x_i$  מסמן את האיבר ה- $i$  של וקטור  $x$  ו- $\bar{x}$  מסמן את הממוצע של וקטור  $x$ . עבור שני וקטורים  $x, y$  באורך  $n$  המכפלה הסקלרית שלהם היא  $x^T y = \sum_{i=1}^n x_i y_i$ . תזכורת: נגדיר מודל לרגרסיה פשוטה עם חותך:  $y_i = \beta_0 + \beta_1 x_i + \epsilon_i$  עבור נתונים  $(x_1, y_1), \dots, (x_n, y_n)$ . עבור מודל זה שגיאת הרבועים הפחותים  $SSE = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n \epsilon_i^2$  ניתנת לכתיבה בצורות הבאות:

$$SSE = (y - \hat{\beta}_0 - \hat{\beta}_1 x)^T (y - \hat{\beta}_0 - \hat{\beta}_1 x) = (y - \bar{y})^T (y - \bar{y}) - \hat{\beta}_1^2 (x - \bar{x})^T (x - \bar{x})$$

$$\hat{\beta}_1 = \frac{(x - \bar{x})^T (y - \bar{y})}{(x - \bar{x})^T (x - \bar{x})}, \quad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

1. עבור מודל הרגרסיה הפשוטה עם חותך לעיל, יהיה  $\hat{y}$  וקטור התחזיות ויהיה  $e = y - \hat{y}$  וקטור השאריות. אילו מהגדלים הבאים תמיד שווים לאפס?  $\sum_{i=1}^n \epsilon_i$ ,  $\sum_{i=1}^n x_i \epsilon_i$ ,  $\sum_{i=1}^n y_i \epsilon_i$

(א) כולם

(ב) אף אחד

(ג) רק  $\sum_{i=1}^n \epsilon_i, \sum_{i=1}^n x_i \epsilon_i$ (ד) רק  $\sum_{i=1}^n \epsilon_i$ (ה) רק  $\sum_{i=1}^n y_i \epsilon_i, \sum_{i=1}^n x_i \epsilon_i$ 

(ו) אף אחת מהתשובות לעיל אינה נכונה

2. נניח כעת כי נתונים כל הסכומים הבאים עבור נתונים  $(x_1, y_1), \dots, (x_n, y_n)$ :

$$S_x = \sum_{i=1}^n x_i = -3.8, S_y = \sum_{i=1}^n y_i = 23.6, S_{xx} = x^T x = 41.45, S_{yy} = y^T y = 69.64, S_{xy} = x^T y = -15.45, n = 20$$

חשבו את  $\hat{\beta}_0, \hat{\beta}_1$  ואת האומד לשונות  $s^2$  עבור מודל הרגרסיה עם חותך והנתונים שלעיל.

$$\hat{\beta}_1 = \frac{-15.45 - \frac{1}{20}(-3.8)23.6}{41.45 - \frac{1}{20}(-3.8)^2} = -0.269$$

$$\hat{\beta}_0 = \frac{1}{20}23.6 - \frac{1}{20}(-3.8)(-0.269) = 1.125$$

$$SSE = 69.64 - \frac{1}{20}(23.6)^2 - (-0.269)^2 \left(41.45 - \frac{1}{20}(-3.8)^2\right) = 38.845$$

$$s^2 = \frac{SSE}{18} = 2.158$$

3. נגדיר כעת מודל רגרסיה ללא חותך:  $y_i = \gamma_1 x_i + \epsilon_i$  עבור נתונים  $(x_1, y_1), \dots, (x_n, y_n)$ . הוכיחו שבמודל זה אומד הרבועים הפחותים  $\hat{\gamma}_1$  עבור  $\gamma_1$  שווה ל- $\frac{x^T y}{x^T x}$ .

---

---

---

---

---

---

---

---

4. עבור רגרסיה לינארית פשוטה, עם שגיאות נורמליות  $\epsilon \sim N(0, \sigma^2 I_n)$  עבור  $\sigma^2 > 0$  יהיו  $\hat{\beta}_0, \hat{\beta}_1, \bar{y}$  אומדי הרבועים הפחותים הרגילים וממוצע ה- $y_i$  בהתאמה עבור מדגם  $D = (x_1, y_1), \dots, (x_n, y_n)$  עם  $n > 1$ . שלושת המשתנים המקריים  $\hat{\beta}_0, \hat{\beta}_1, \bar{y}$  הם:

(א) תלויים וכל הזוגות תלויים

(ב) בלתי תלויים

(ג) תלויים, חלק מהזוגות תלויים וחלק מהזוגות בלתי תלויים

(ד) תלויים, אך בלתי תלויים בזוגות

5. נתונה המטריצה  $A = \begin{bmatrix} 1 & 1 \\ 1 & 2 \\ 3 & -1 \end{bmatrix}$  והוקטור  $v = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}$ . תהיה  $P_A = A[A^T A]^{-1} A^T$  מטריצת הטלה על תת המרחב הנפרש על ידי עמודות  $A$  ותהי  $P_{A^\perp}$  מטריצת הטלה על תת המרחב הניצב לתת המרחב הנפרש על ידי עמודות  $A$ . חשבו את הגדלים הבאים: (כתבו את התוצאות כוקטורי שורה. כתבו רק תוצאה סופית - אין צורך להראות דרך)

$$P_A v = \frac{1}{33} (14, 25, -2) \quad (\alpha)$$

$$P_{A^\perp} v = \frac{1}{33} (-14, 8, 2) \quad (\beta)$$

$$P_{A^\perp} P_A v = (0, 0, 0) \quad (\gamma)$$

$$\begin{aligned} A^T A &= \begin{bmatrix} 11 & 0 \\ 0 & 6 \end{bmatrix} & A^T v &= \begin{bmatrix} 1 \\ 2 \end{bmatrix} \\ P_A v &= A[A^T A]^{-1} A^T v = A \begin{bmatrix} 1/11 \\ 1/3 \end{bmatrix} = \frac{1}{33} \begin{bmatrix} 14 \\ 25 \\ -2 \end{bmatrix} = \begin{bmatrix} 0.424 \\ 0.757 \\ -0.060 \end{bmatrix} \\ P_{A^\perp} v &= v - P_A v \end{aligned}$$